

# Detección, clasificación y estimación de daños en hélices de vehículos multirrotor

Gabriel Torre<sup>1,2</sup>, Claudio Pose<sup>1,3,4</sup> y Juan Giribet<sup>1,4</sup>

<sup>1</sup>Laboratorio de Inteligencia Artificial y Robótica, Universidad de San Andrés

<sup>2</sup>Instituto de Ingeniería Biomédica, Facultad de Ingeniería, Universidad de Buenos Aires

<sup>3</sup>Laboratorio de Automática y Robótica, Facultad de Ingeniería, Universidad de Buenos Aires

<sup>4</sup>Consejo Nacional de Investigaciones Científicas y Técnicas (CONICET)

**Resumen**—Este artículo presenta una arquitectura y metodología de entrenamiento para un procedimiento de aprendizaje automático, destinado a detectar, identificar y cuantificar daños en las hélices de vehículos aéreos no tripulados (UAV) multirrotor. Se recopilaban datos de vuelo de un vehículo multirrotor donde alguna de sus hélices fue reemplazada por una dañada, con tres tipos distintos de daños y de variada magnitud. Estos datos fueron luego utilizados para entrenar un modelo por partes, que incluye tanto clasificadores como redes neuronales, capaz de identificar con precisión el tipo de falla, estimar la gravedad del daño y localizar el rotor afectado. Los datos empleados para este análisis provienen exclusivamente de mediciones inerciales y comandos de control. Esta elección estratégica asegura la adaptabilidad de la metodología propuesta en diversas plataformas de vehículos multirrotor.

**Index Terms**—Vehículos aéreos no tripulados, detección de fallas, aprendizaje estadístico, redes neuronales.

## I. INTRODUCCIÓN

A medida que el uso de los UAV crece, particularmente en proximidad a humanos, la seguridad y fiabilidad de estos vehículos se han vuelto primordiales, requiriendo un alto nivel de confiabilidad de la aeronave. El operador (o equipo de operadores) siempre debe asegurar un buen mantenimiento de las diferentes partes del vehículo para operar en los niveles de seguridad más altos posibles. Sin embargo, los UAV siguen siendo susceptibles a daños durante su operación.

En este aspecto, una de las partes del vehículo que generalmente demanda más mantenimiento y cuya falla es crítica para asegurar la continuidad de un vuelo, es el subsistema de actuadores, compuesto por un número fijo de pares rotor-hélice que es altamente susceptible al desgaste. Factores como condiciones ambientales adversas (por ejemplo, operaciones en áreas polvorientas o arenosas) e impactos físicos pueden degradar significativamente su rendimiento. Esta degradación no solo reduce la eficiencia sino que también aumenta vibraciones no deseadas, potencialmente llevando a fallos catastróficos y accidentes. Aunque algunos tipos de daños pueden ser modelados con precisión a través de ecuaciones físicas, para otros tipos puede ser imposible hacerlo. Por ejemplo, abolladuras, puntas rotas o daños estructurales en las hélices pueden comportarse de diferentes maneras según su velocidad de rotación y aceleración, y el estado del ambiente, considerando su interacción con el viento y otros factores. Estas

complejidades hacen difícil, si no imposible, modelar con precisión su impacto usando ecuaciones físicas tradicionales.

Cuando el tipo de fallas se vuelve más difícil de discernir mediante un comportamiento predecible de un modelo, y más aún cuando la relación entre la naturaleza de la falla y los efectos en el vehículo son difíciles de modelar o incluso saber si hay una relación, los enfoques basados en datos se convierten en una herramienta útil. Por ejemplo, en el caso de [1], se propone un clasificador de tipo *support vector machine* (SVM) para tratar la pérdida de eficiencia en una hélice, que es un problema bastante común en los UAVs multirrotor debido al desgaste de los actuadores y condiciones ambientales adversas. Otro clasificador SVM se propone en [2], para detectar fallas en octorrotores coaxiales utilizando mediciones directas de corriente y velocidad, donde la presencia de dos rotores contiguos dificulta saber cuál presenta la falla. Aunque el conjunto de actuadores en su totalidad ha sido enfocado por varios investigadores, las fallas más comunes abordadas han sido generalmente relacionadas con la pérdida de eficiencia, falla total o bloqueo.

Últimamente, a medida que se desarrollan nuevas técnicas, el interés ha aumentado en una categoría específica de fallas, a saber, aquellas que se relacionan con la interacción entre rotor y hélice, y particularmente el daño estructural en esta última. Por ejemplo, [3] propone un enfoque de red neuronal para detectar un deslizamiento entre el rotor y la hélice, para lo cual es necesario medir la velocidad de las hélices. Un problema similar se discute en [4], donde la solución se basa en redes neuronales convolucionales profundas y redes neuronales recurrentes (Deep CNN y LSTM) para detectar la rotura de la hélice.

El daño estructural en las hélices es de particular interés, ya que necesitan estar en perfectas condiciones, o su masa rotativa desequilibrada a alta velocidad puede inyectar perturbaciones en la estructura y afectar varios sensores, o incluso deteriorar el resto de la estructura. Los sensores inerciales, que son los sensores mínimos e indispensables que un UAV necesita para volar, se ven gravemente afectados por las vibraciones en la estructura del vehículo, hasta el punto de que la información que proporcionan puede volverse inutilizable. Sin embargo, estos sensores también son útiles para detectar la ocurrencia de dicho daño, y también para establecer alguna relación entre la naturaleza del daño y la perturbación que produce.

Los trabajos en [5], [6] muestran que, si se trabaja con el dominio de frecuencia de los datos inerciales, es posible detectar la frecuencia de rotación de los motores, ya que producen vibraciones pequeñas pero notables alrededor de esa frecuencia. Entonces, como el daño que afecta a una hélice aparece como una vibración notable en el dominio de frecuencia, el desplazamiento en frecuencia o un cambio en la densidad de potencia se pueden usar para detectar la naturaleza y características de dicho daño. Varios trabajos han explotado las propiedades del espectro de frecuencia, como [7], donde esta información se utiliza para detectar la presencia de una hélice dañada, limitada al despegue y aterrizaje del vehículo. Esta solución también se implementa en [8], donde se añaden sensores inerciales junto a cada rotor, para capturar la perturbación inyectada por las hélices dañadas, y usando la energía en varias bandas de frecuencia para detectar en qué motor estaba presente el daño, incluyendo daños simultáneos en dos hélices.

En este trabajo, el objetivo es proporcionar una arquitectura basada en datos que sea capaz de detectar la existencia o aparición de daños en una hélice, detectar la ubicación de la hélice dañada y estimar el tipo y grado de daño que presenta. Se consideran varios tipos de daño, cada uno potencialmente causando uno o más efectos señalados en investigaciones anteriores, incluyendo pérdida de eficiencia, desequilibrio de masa y cambios en el área efectiva. Como datos de entrada, el trabajo se limitará al uso de datos inerciales y señales de control, de forma tal de evidenciar que la solución propuesta puede extenderse a cualquier vehículo multirrotor. Esta arquitectura proporcionará una solución que permita un mantenimiento preciso y proactivo, y que también permita la recuperación de fallas en vuelo. La solución propuesta será evaluada usando una plataforma tipo cuadricóptero.

Los aportes principales del trabajo se listan a continuación:

- **Identificación del Tipo y Gravedad del Daño:** Desarrollo de un modelo que identifica el tipo de daño (simétrico, asimétrico o longitudinal) y estima su magnitud.
- **Localización de la Hélice Dañada:** Introducción de un clasificador que determina cuál de las hélices del UAV está dañada usando solo datos inerciales y variables de control.
- **Validación en Diferentes Plataformas:** Validación de la metodología propuesta en el dataset público UAV-FD [9], demostrando su adaptabilidad y efectividad en diversas configuraciones de vehículos aéreos.

## II. FALLAS CONSIDERADAS

Considerando la amplia gama de escenarios de daños potenciales que podrían afectar a una hélice, que incluyen melladuras en todos los lugares imaginables, diversas deformaciones y cualquier tipo de rotura, las consideraciones prácticas requieren un enfoque centrado. Utilizando un conjunto representativo de daños, se espera abarcar un amplio conjunto de posibles situaciones y extender los resultados hacia la mayor cantidad de casos reales posibles.



Figura 1: Hélices con daño: A-longitudinal, B,C-asimétrico, y D-simétrico.

Primero, se considera un daño simétrico, donde ambas puntas de las hélices se cortan a la misma longitud, como se muestra en la Fig. 1.D. Su comportamiento vibratorio es similar al de una hélice sana, pero resulta en una pérdida de empuje y torque que produce el rotor. Este tipo de falla abarca varios efectos que pueden aparecer en un conjunto rotor-hélice, tales como el desgaste de la hélice y de los rulemanes del rotor, lo que produce fricción y disminución de la eficiencia.

Un segundo tipo de daño es aquel en el que también se cortan ambas puntas pero a diferentes longitudes, como se muestra en la Fig. 1.B-C. Este tipo de daños son consistentes con que el vehículo roce o choque suavemente con otro objeto, donde una de las hélices puede impactar brevemente con una superficie dura y sufrir una pequeña rotura en una o ambas de sus puntas, que estadísticamente nunca serán iguales. Si bien también hay pérdida de eficiencia, el desequilibrio de masa en una hélice de alta velocidad de rotación introducirá severas vibraciones. Este tipo de falla podría ser crítica para los vehículos, ya que las vibraciones que se transmiten a la estructura pueden afectar gravemente las mediciones inerciales de los sensores y, en consecuencia, imposibilitar la estimación de la orientación del vehículo.

El último tipo de falla analizada es un corte longitudinal de la misma longitud en ambas puntas, como se presenta en la Fig. 1.A. Este daño podría ser causado por una colisión, o también por la separación de fibras de carbono en hélices fabricadas con este material. En este caso no se pierde superficie de la hélice ni se produce ningún tipo de desequilibrio de masas. Sin embargo, el comportamiento de la hélice a cualquier velocidad dada es impredecible, ya que el *blade flapping* puede introducir cualquier tipo de vibración o un empuje/torque diferente al esperado. Este tipo de falla debería ser difícil de identificar, ya que sus efectos pueden variar dependiendo de la maniobra que se esté ejecutando, las condiciones del viento e incluso la temperatura que puede causar que las puntas se doblen.

Si bien los daños pueden aparecer en más de una hélice al mismo tiempo, en este trabajo se partirá de la premisa de que sólo hay una hélice dañada, y el objetivo es detectar cuál es la hélice dañada, y que tipo de daño y magnitud la afecta.

## III. SELECCIÓN DE DATOS

Para obtener datos realistas, los mismos se recolectaron utilizando un vehículo experimental, el cual se muestra en



Figura 2: Plataforma quadrotor para la recolección de datos

la Fig. 2. Se seleccionó un vehículo quadrotor por ser la estructura fija multirotor más simple, donde todos los pares rotor-hélice están a la misma distancia radial del centro del vehículo, simétricamente distribuidos en el plano horizontal. Este modelo en particular se basa en el multirrotor DJI F450, con rotores de 920 KV y hélices de plástico 1045, capaces de generar 1 kg de empuje cada una. El controlador de vuelo es un Pixhawk 2.4.8, con magnetómetro externo, y un receptor DSMX del radiocontrol Spektrum. Las tareas del controlador de vuelo incluyen la recopilación de mediciones de sensores, filtrado de datos, estimación de orientación y control individual de motores, así como recolección de datos y recepción de comandos de un controlador RC. El sistema funciona con una batería LiPo (14,8 V) de 4 s, siendo el peso total del sistema 1,5 kg.

Los datos mínimos necesarios para volar uno de estos vehículos son los que proporciona una IMU (Unidad de Medición Inercial), que proporciona aceleración y mediciones giroscópicas tridimensionales. Estos datos son necesarios para estimar la orientación del vehículo con el fin de estabilizarlo en el aire, y junto con la información provista por un magnetómetro se completa la estimación tridimensional de la orientación.

Para controlar la orientación del vehículo, se ejecutan varios algoritmos de control que comparan la orientación deseada con la estimada, y generan un conjunto de torques para comandar el vehículo. El conjunto de torques calculados se transforma luego en un conjunto de velocidades comandadas para cada uno de los rotores, estando toda esta información disponible para ser utilizada o almacenada. La última variable de control necesaria para hacer volar el vehículo es el empuje vertical, la cantidad combinada de fuerza que ejercen todos los rotores, y que definirá la aceleración vertical. Generalmente tendrá un valor medio igual al peso del vehículo para lograr el vuelo estacionario, y aumentará o disminuirá ligeramente durante las maniobras.

El proceso de obtener un conjunto de mediciones de la IMU, estimar la orientación del vehículo, calcular los torques necesarios para alcanzar la orientación deseada y comandar las velocidades necesarias a los rotores es un ciclo que se ejecuta periódicamente a una frecuencia fija, que generalmente varía en el rango de 100 Hz-400 Hz dependiendo del vehículo. En este vehículo en particular, el controlador Pixhawk permite configurar una velocidad de datos de 222 Hz, registrando en su memoria micro SD los datos de los sensores y variables de control de cada ciclo.

Con este vehículo, se realizaron una gran cantidad de vuelos, en cada uno de ellos reemplazando una de la hélices sanas por una con algún tipo de daño de diferente magnitud de los anteriormente mencionados. Inicialmente, el vehículo despegó y permanece estacionario en el aire, realizando sólo ligeras maniobras de corrección durante los primeros 40 s. Durante los siguientes 40 s, el vehículo ejecuta varias maniobras suaves, incluidas rotaciones lentas en cada eje y ascensos y descensos graduales. En los 40 s finales, el vehículo realiza maniobras agresivas en cada eje, combinadas con ascensos y descensos abruptos, para luego aterrizar.

Todos los vuelos se realizaron mientras la hélice averiada se encontraba situada en el mismo motor, el delantero derecho. Para tener un conjunto de datos completo para identificar en qué rotor se encontraba la hélice dañada, se debería haber repetido el mismo conjunto de experimentos pero cambiando la ubicación de la hélice dañada. Sin embargo, debido a la simetría del vehículo, fue fácil realizar *data augmentation* y generar los tres conjuntos de datos restantes, uno para cada motor fallado, realizando una rotación adecuada alrededor del eje  $z$  del vehículo.

Los datos de vuelo registrados, así como los algoritmos utilizados para entrenar y probar la solución propuesta, se pueden encontrar en [10].

#### IV. ARQUITECTURA

Para proponer una arquitectura basada en datos, se decidió utilizar los datos provistos por los sensores inerciales (tres acelerómetros y giróscopos), los torques comandados al vehículo (uno por cada eje) y el empuje vertical. Considerando un enfoque basado en las características espectrales de estos datos, se calcula la energía espectral de cada sensor o torque en bandas de 5 Hz, para un total de 22 bandas en el espectro observable de 111 Hz. Además, se calculan valores de media, varianza, asimetría y Kurtosis de los tres torques comandados. El cálculo de bandas de energías para todos los sensores y torques, además de los valores estadísticos, se realiza en ventanas de tiempo de 1 s sobre los datos recolectados.

La arquitectura de la red se muestra en la Fig. 3. Primero un clasificador basado en SVM detecta si existe o no una hélice dañada, y si se trata de un daño simétrico/asimétrico, o longitudinal. La decisión de agrupar los tipos simétricos y asimétricos se tomó porque, durante las pruebas preliminares, la estimación de la magnitud de la falla tuvo un buen desempeño ya sea al tratar los dos tipos por separado o en conjunto, probablemente debido a la naturaleza del daño y efectos

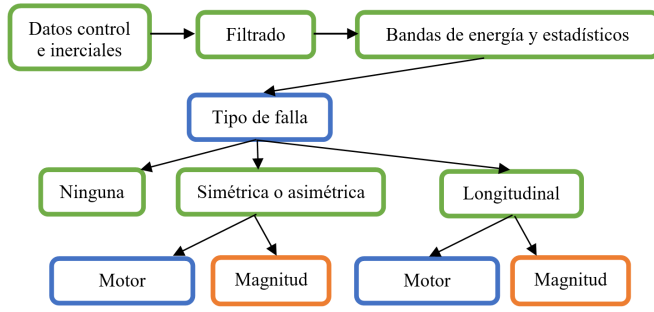


Figura 3: Arquitectura propuesta

similares en el espectro en frecuencia. En este clasificador en particular, como se realizó un solo vuelo con hélices sanas, mientras que cuatro con daños longitudinales y 13 con daños simétricos y asimétricos, hay un gran desequilibrio en los datos, ya que cada vuelo aporta aproximadamente la misma cantidad de muestras. Por lo tanto se realizó un procedimiento de agrupamiento basado en *K-means*, reduciendo el conjunto de datos a un grupo de *clusters* con la misma cantidad de muestras representativas.

Luego, para cada posible clase de daño, se entrenó una red neuronal para estimar la magnitud del daño y un clasificador SVM para detectar en cuál de los cuatro rotores se encontraba la hélice dañada. Para el daño simétrico/asimétrico, la red neuronal tiene dos salidas, una es la suma de la longitud cortada de ambas puntas, y la otra es la diferencia absoluta entre ellas (ambas en milímetros, positivas), para tener una medida representativa del daño por pérdida de superficie y desequilibrio en una hélice. En el caso longitudinal existe una única salida que es la suma de los cortes en ambas puntas, para tener un planteamiento similar al caso anterior.

Para detectar en qué motor se localiza el daño, si bien las clases estaban balanceadas, como la cantidad de datos era grande y el entrenamiento demoraba un tiempo considerable, se realizó otra agrupación por *K-means* para reducir la cantidad de datos a una más manejable y acelerar el proceso de entrenamiento.

Los clasificadores SVM se entrenaron usando la biblioteca *sklearn* para *python*, particularmente *sklearn.svm.SVC*, con un núcleo lineal y salida de probabilidad para un mejor análisis.

Las redes neuronales se resolvieron utilizando la biblioteca *torch*, con una arquitectura compuesta por 232 entradas y tres capas ocultas con 32, 8 y 4 neuronas con función de activación ReLU. Para entrenarlos se utilizó la función de pérdida MSE, así como el optimizador Adadelta que mostró mejor rendimiento que Adam, Adagrad y SGD. Se seleccionó una tasa de aprendizaje de 0.1 después de varias rondas de entrenamiento, para obtener una evolución suave y consistentemente decreciente de la pérdida durante 200 epochs.

## V. ENTRENAMIENTO Y RESULTADOS

Esta sección presenta los resultados obtenidos para los distintos bloques de la arquitectura propuesta, teniendo en cuenta la estructura particular y los métodos de entrenamiento descritos en la sección anterior.

Tabla porcentual [%]		Clase predicha		
Clase verdadera	Daño [mm-mm]	C0	C1	C2
C0	0-0	<b>97.71</b>	0.89	1.39
	5-5	34.85	<b>62.51</b>	2.64
	10-10	10.44	<b>86.97</b>	2.59
	15-15	0.88	<b>98.50</b>	0.62
	20-20	0.00	<b>99.62</b>	0.38
	25-25	0.22	<b>99.34</b>	0.44
	30-30	1.40	<b>96.69</b>	1.91
	35-35	0.13	<b>92.93</b>	6.94
	40-40	0.27	<b>99.47</b>	0.27
	0-5	6.49	<b>42.92</b>	50.59
C1	0-10	4.43	<b>93.98</b>	1.59
	0-15	0.00	<b>98.28</b>	1.72
	10-15	8.24	<b>81.26</b>	10.50
	10-20	0.26	<b>99.74</b>	0.00
	10-10	4.40	2.88	<b>93.06</b>
	20-20	2.72	1.99	<b>95.29</b>
	30-30	2.63	4.00	<b>93.38</b>
	40-40	2.06	1.96	<b>95.98</b>
	10-10	4.40	2.88	<b>93.06</b>
	20-20	2.72	1.99	<b>95.29</b>
C2	30-30	2.63	4.00	<b>93.38</b>
	40-40	2.06	1.96	<b>95.98</b>

Tabla I: Predicción del tipo de daño para cada uno de los vuelos. El daño de la hélice se expresa en recortes en milímetros de cada punta.

### V-A. Clasificación del tipo de daño

En la Tabla I, se presenta la matriz de confusión para el clasificador de daño, separada por vuelo. Cada fila corresponde a un vuelo único con una hélice dañada diferente. La clase *C0* corresponde a un vuelo sin hélices dañadas, la clase *C1* a una hélice dañada de manera simétrica o asimétrica, y *C2* a una hélice con daño longitudinal.

Los resultados muestran un muy buen desempeño clasificando las muestras correspondientes a un vuelo con hélices sanas, ya que hay una alta probabilidad de pertenecer a esa clase para todas las muestras tomadas durante ese vuelo. Las excepciones se hallan en aquellos tipos de daño muy pequeño, por ejemplo para la hélice con daño simétrico con 5 mm de recorte en cada punta. En este caso, la hélice presenta un casi nulo desbalance y una muy pequeña pérdida de empuje, con lo cual es muy difícil distinguirla de una hélice sana.

### V-B. Estimación y localización del daño simétrico y asimétrico

Si una muestra se clasifica correctamente como correspondiente a un daño simétrico o asimétrico, entonces las mismas características se utilizan para estimar la magnitud y localización de la hélice dañada, mediante una red neuronal y un nuevo clasificador, respectivamente.

En cuanto a la estimación de la magnitud del daño, los resultados se presentan en la Fig 4. Los gráficos presentan la estimación en la diferencia (arriba) y suma (abajo) de los recortes realizados en ambas puntas, para cada una de las muestras de 1 s, tomadas de cada uno de los vuelos realizados (separados por líneas verticales punteadas). En cada uno de los vuelos, se indica con dos números en la parte inferior las magnitudes de los recortes de ambas puntas en milímetros, de manera similar a la Tabla I. Puede observarse que para los vuelos con daño simétrico (los primeros 8), la estimación de la diferencia entre los recortes de cada punta es muy cercana

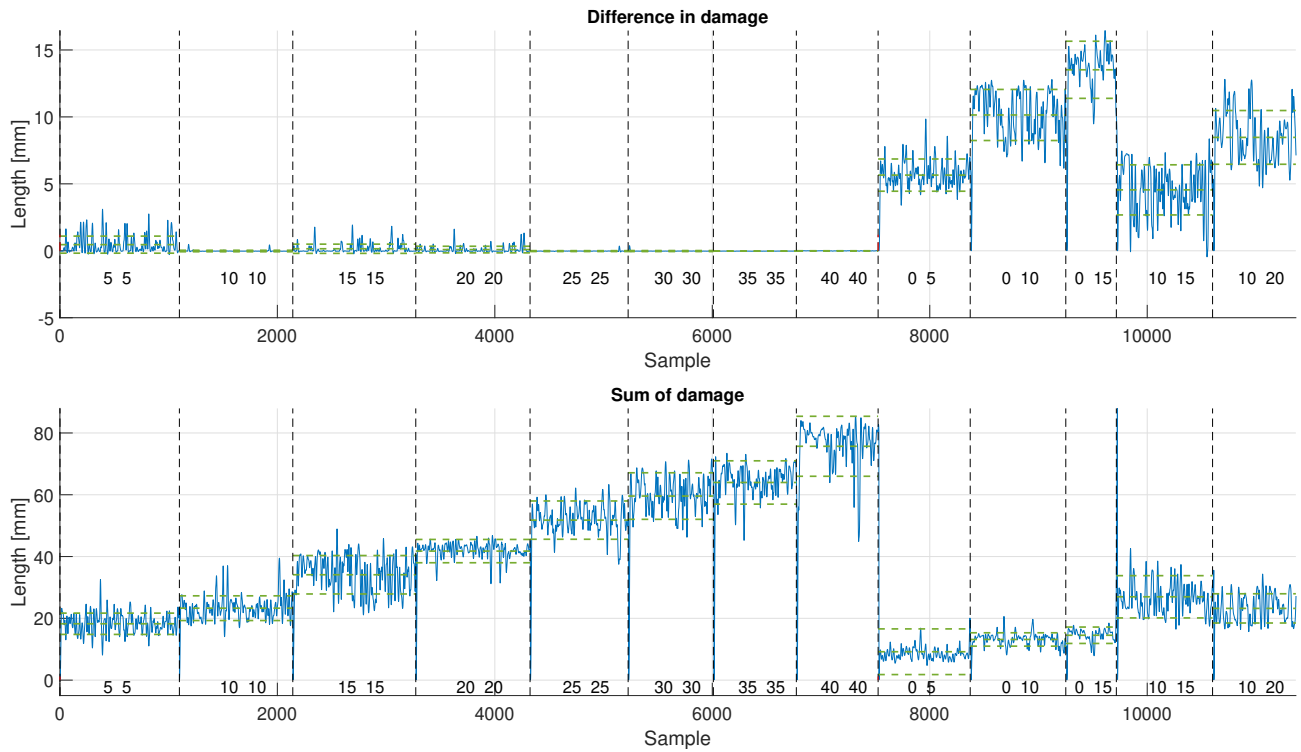


Figura 4: Estimación de la suma y diferencia en el daño para los vuelos con daño simétrico y asimétrico.

Porcentaje [%]		Clase predicha			
		C1	C2	C3	C4
Clase verdadera	C1	<b>88.77</b>	0.54	10.39	0.3
	C2	0.51	<b>89.59</b>	0.29	9.62
	C3	10.28	0.74	<b>88.81</b>	0.18
	C4	0.44	10.29	0.46	<b>88.83</b>

Tabla II: Rendimiento en la detección de la ubicación de la falla para daño simétrico y asimétrico.

a cero, mientras que la suma es cercana a los valores reales de daño (excepto, por ejemplo, para la hélice con daño 5-5, donde presenta mayor error de estimación).

En cuanto a la localización de la hélice dañada, la Tabla II muestra la matriz de confusión del clasificador, donde puede apreciarse una tasa de aciertos en cuanto a la hélice dañada de alrededor del 90 % para todos los casos. Sin embargo, hay alrededor de un 10 % de clasificaciones erróneas en todos los casos, donde se detecta como fallada la hélice diametralmente opuesta. Es posible que la causa de confusión sea que el clasificador es capaz de detectar el eje sobre el que se produce la falla, pero no logra discernir adecuadamente cuál de los motores que generan torque sobre ese eje es el causante.

#### V-C. Estimación y localización de daño longitudinal

De manera análoga, se implementó una solución para una muestra clasificada como falla longitudinal, donde se utilizan las mismas características para estimar la magnitud del daño y su ubicación. La Fig. 5 muestra la suma estimada de las longitudes de corte para cada uno de los cuatro vuelos con




Figura 5: Estimación de la suma y diferencia en el daño para los vuelos con daño longitudinal.

una hélice con ese tipo de daño. A diferencia de los resultados anteriores, aquí se ve que las estimaciones son más ruidosas y se desvían más del valor real a medida que aumenta el grado de daño, probablemente debido a las pequeñas variaciones en las características para cada tipo de daño. Esto es debido a que la variación en el espectro para cada magnitud de daño es muy sutil, y es difícil discernir entre ellas.

La matriz de confusión para la localización del daño se presenta en la Tabla III. De manera similar a lo que sucede con el daño simétrico y asimétrico, el clasificador es capaz de detectar que hay un problema en algún eje, ya que asigna consistentemente la ubicación del fallo ya sea al rotor correcto o al opuesto.

#### V-D. Demanda computacional y uso a bordo

Con el objetivo de utilizar el método en tiempo real en un futuro se realizaron pruebas preliminares de tiempo de



Porcentaje [%]		Clase predicha			
		C1	C2	C3	C4
Clase verdadera	C1	<b>72.42</b>	0.30	27.00	0.27
	C2	0.22	<b>72.86</b>	0.66	26.29
	C3	26.89	0.27	<b>72.64</b>	0.22
	C4	0.11	26.48	0.44	<b>73.00</b>

Tabla III: Rendimiento en la detección de la ubicación de la falla para daño longitudinal.

Porcentaje [%]		Clase predicha		
		Sin Fallo	5 % fallo	10 % fallo
Clase verdadera	Sin fallo	<b>98.80</b>	0.40	0.80
	5 % fallo	0.00	<b>99.00</b>	1.00
	10 % fallo	1.00	1.70	<b>97.30</b>

Tabla IV: Matriz de confusión del método aplicado al dataset UAV-FD.

ejecución en una Raspberry Pi 4B con 4 GB de RAM, utilizando Python 3.9.2 y Pytorch 1.13.0, obteniendo como resultado 42.29 inferencias por segundo, sin considerar ningún tipo de optimización del código. En el futuro, se utilizará como plataforma una NVIDIA Jetson TX2, la cual incrementará significativamente la velocidad del algoritmo.

## VI. VALIDACIÓN

La metodología propuesta en este trabajo se validó con el dataset UAV-FD, publicado por [9], donde se presenta un desafío de clasificación multiclase con tasas de fallo distintas (sin fallo, 5 % y 10 % de la longitud de la hélice) en un vehículo con seis rotores. Utilizando un clasificador SVM cuadrático, los autores de [9] logran una precisión máxima del 98.5 % en el conjunto de pruebas. Este rendimiento se logró mediante el entrenamiento sobre un conjunto de características principales determinadas a través de un análisis de varianza (ANOVA), que abarcan parámetros cruciales como velocidades y corrientes de motores, actitudes estimadas y deseadas, velocidades y datos de vibración.

Para aplicar la solución propuesta en este trabajo, se tomó dicho dataset y se redujo el conjunto de características para incluir sólo datos de giróscopos, acelerómetros y señales de comando PWM a cada motor, para luego extraer de las mismas sus características espectrales. Cabe mencionar que el conjunto de datos publicado carecía de información sobre los torques comandados, por lo tanto, las señales de comando PWM sirvieron como un sustituto. Esto es debido a la correspondencia entre las señales PWM comandadas y los torques deseados, los cuales están relacionados a través de una matriz constante. Empleando una red neuronal como la detallada anteriormente, el enfoque propuesto en este trabajo logró una precisión del 98.8 % (promedio de cinco ejecuciones) como se observa en la Tabla IV. Este resultado no solo resalta la adaptabilidad y efectividad del método propuesto, sino que también demuestra su sólido rendimiento en un tipo de vehículo diferente, un hexarotor en este caso particular.

## VII. DISCUSIÓN Y CONCLUSIONES

Los resultados presentados demuestran la viabilidad de estimar tanto el tipo como la severidad de las fallas mediante

la metodología propuesta. En muchos casos, la red logró un rendimiento adecuado, evaluado tanto en el conjunto de dataset obtenido en nuestros ensayos como en uno proporcionado por otro grupo, bajo condiciones diferentes e incluso con otro vehículo.

Además, se llevaron a cabo estudios complementarios sobre la red, aunque no se presentan aquí. Se exploraron variaciones en la arquitectura de la red y se evaluó la importancia de cada característica. Este análisis resultó especialmente relevante, ya que se observó la contribución de incluir información sobre el torque, una consideración que no se había abordado en trabajos previos. También se investigaron las bandas de frecuencia óptimas para realizar el entrenamiento y la detección.

Basándose en estos estudios, se considera que se logró un esquema de detección basado en datos que ofrece robustez, capaz de no solo identificar la presencia de una falla, sino también su gravedad. Sin embargo, es importante tener en cuenta que este esquema es demandante desde el punto de vista del hardware requerido, lo que motiva a investigar cómo lograr una implementación más eficiente que permita integrar esta arquitectura con sistemas de control en tiempo real. Este paso sería crucial para lograr una respuesta adaptativa ante la detección de fallas en vuelo.

## REFERENCIAS

- [1] E. Baskaya, M. Bronz, and D. Delahaye, "Fault detection & diagnosis for small uavs via machine learning," in *2017 IEEE/AIAA 36th Digital Avionics Systems Conference (DASC)*, 2017, pp. 1–6.
- [2] M. Saied, B. Lussier, I. Fantoni, H. Shraim, and C. Francis, "Fault diagnosis and fault-tolerant control of an octorotor uav using motors speeds measurements," *IFAC-PapersOnLine*, vol. 50, no. 1, pp. 5263–5268, 2017, 20th IFAC World Congress. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S2405896317308315>
- [3] P. Kantue and J. O. Pedro, "Integrated fault detection and diagnosis of an unmanned aerial vehicle using time difference of arrival," in *2020 24th International Conference on System Theory, Control and Computing (ICSTCC)*, 2020, pp. 336–342.
- [4] V. Sadhu, K. Anjum, and D. Pompili, "On-board deep-learning-based unmanned aerial vehicle fault cause detection and classification via fpgas," *IEEE Transactions on Robotics*, vol. 39, no. 4, pp. 3319–3331, 2023.
- [5] B. Ghalamchi and M. Mueller, "Vibration-based propeller fault diagnosis for multicopters," in *2018 International Conference on Unmanned Aircraft Systems (ICUAS)*, 2018, pp. 1041–1047.
- [6] B. Ghalamchi, Z. Jia, and M. W. Mueller, "Real-time vibration-based propeller fault diagnosis for multicopters," *IEEE/ASME Transactions on Mechatronics*, vol. 25, no. 1, pp. 395–405, 2020.
- [7] A. Benini, F. Ferracuti, A. Monteriù, and S. Radensleben, "Fault detection of a vtol uav using acceleration measurements," in *2019 18th European Control Conference (ECC)*, 2019, pp. 3990–3995.
- [8] A. Bondyra., P. Gasior., S. Gardecki., and A. Kasiński., "Development of the sensory network for the vibration-based fault detection and isolation in the multirotor uav propulsion system," in *Proceedings of the 15th International Conference on Informatics in Control, Automation and Robotics - Volume 2: ICINCO, INSTICC*. SciTePress, 2018, pp. 102–109.
- [9] A. Baldini, L. D'Alleva, R. Felicetti, F. Ferracuti, A. Freddi, and A. Monteriù, "Uav-fd: a dataset for actuator fault detection in multirotor drones," in *2023 International Conference on Unmanned Aircraft Systems (ICUAS)*, 2023, pp. 998–1004.
- [10] "Quadrotor with propeller damage dataset," <https://github.com/udes-a-i/propeller-damage-detection-classification-and-estimation-in-multirotor-vehicles-2024>, [Online, accessed: 2024-01-24].