

Base de Datos para Conducción Autónoma. Sensores y Sincronización

Juan Giribet^{1,2}, Ignacio Mas^{1,2}, Agustín Roca¹, Guillermo Marzik^{1,2}, Gabriel Torre¹, Claus Rosito¹ y Gastón Castro^{1,2}

¹Laboratorio de Inteligencia Artificial y Robótica. Universidad de San Andrés y ²CONICET

Email: linar@udesa.edu.ar

Resumen—En este trabajo, presentamos una nueva base de datos diseñada para aplicaciones de conducción autónoma en el Área Metropolitana de Buenos Aires (AMBA). Esta base de datos recopila información de diversas fuentes de sensores, incluyendo cámaras, LiDAR, GPS, IMU y micrófono, ofreciendo una rica diversidad de perspectivas y dimensiones para el análisis. Detallamos el montaje de los sensores y la estructura del conjunto de datos, incluyendo los procesos de calibración y sincronización para garantizar la precisión y la utilidad de la información recogida.

Comparando nuestra base de datos con otras existentes, destacamos las singularidades y las ventajas del enfoque propuesto, que se centra en la variedad y la profundidad de los datos recopilados, especialmente adaptados a las peculiaridades del entorno urbano y vial del AMBA en la Argentina. Presentamos también resultados experimentales que demuestran la aplicabilidad de nuestra base de datos en el desarrollo y la mejora de sistemas de conducción autónoma, proponiendo un marco para futuras investigaciones y aplicaciones en este campo emergente.

I. INTRODUCCIÓN

La conducción autónoma representa uno de los desafíos más significativos y transformadores en el campo de la robótica y la inteligencia artificial, prometiendo revolucionar el transporte y la movilidad urbana en las próximas décadas. A pesar de los importantes avances tecnológicos en esta área, la autonomía vehicular en entornos urbanos complejos sigue siendo un problema no completamente resuelto, planteando desafíos relacionados con la percepción, la toma de decisiones y la interacción vehículo-entorno. Uno de los pilares fundamentales para el avance de los sistemas de conducción autónoma es el desarrollo y la disponibilidad de bases de datos extensas y diversificadas que permitan entrenar, validar y probar los algoritmos de inteligencia artificial y aprendizaje profundo que los sustentan.

El entorno urbano del AMBA (área metropolitana de Buenos Aires) presenta características únicas que plantean desafíos específicos para la conducción autónoma, incluyendo la diversidad arquitectónica, las variaciones en las señalizaciones viales, y las dinámicas particulares del tráfico y la interacción con peatones. Estos elementos subrayan la necesidad de desarrollar una base de datos que refleje las peculiaridades de estas condiciones, facilitando así la investigación y el desarrollo de sistemas autónomos que puedan operar de manera efectiva y segura en dichos entornos.



Figura 1: Auto utilizado con los sensores montados

En este contexto, nuestro trabajo se centra en la creación de una base de datos exhaustiva de calles en el AMBA¹, diseñada específicamente para la investigación y el desarrollo de tecnologías de conducción autónoma. Este conjunto de datos incorpora una variedad de sensores, incluyendo cámaras, un LiDAR, receptores de GPS-RTK, IMU y un micrófono, capturando una representación rica y multifacética del entorno urbano. El objetivo principal de este esfuerzo es proporcionar a la comunidad científica y tecnológica un recurso valioso que permita abordar los desafíos de la conducción autónoma con un enfoque específico en las particularidades del contexto de nuestra región.

A lo largo de este trabajo, describiremos en detalle la metodología empleada para la recopilación y el procesamiento de los datos, la estructura y las características del conjunto de datos, y los procesos de calibración de los sensores utilizados. Asimismo, compararemos nuestra base de datos con otras existentes en el ámbito internacional, destacando las contribuciones únicas y el valor añadido de nuestro trabajo. Finalmente, presentaremos aplicaciones y casos de estudio que ilustran el potencial de nuestra base de datos para impulsar la investigación y el desarrollo en el ámbito de la conducción autónoma, con un enfoque particular en la adaptación y optimización de tecnologías para el entorno específico de áreas urbanas de la República Argentina.

¹Acceso a base de datos: <https://github.com/udesa-ai/auto-dataset>

II. DESCRIPCIÓN DEL VEHÍCULO UTILIZADO




Figura 2: Disposición de los sensores. La numeración sigue la de la lista de sensores presentada en la Sección III. H: Sensor de efecto Hall.




Figura 3: Campo de visión de las cámaras.

El vehículo utilizado para las pruebas es un Ford Fusion Hybrid del año 2017 (ver Figura 1), el cual fue intervenido por una empresa extranjera, Voyage, para equiparlo con un sistema drive-by-wire que permite el control por computadora de todos los comandos del automóvil. Este sistema de drive-by-wire proporciona una plataforma flexible y adaptable para la investigación en conducción autónoma, permitiendo una integración simple de algoritmos y sistemas de navegación, guiado y control desarrollados en el entorno de simulación hacia la operación del vehículo real. Además del sistema de control electrónico, el vehículo cuenta con una serie de sensores distribuidos de manera adecuada para proporcionar una percepción completa del entorno circundante.

III. MONTAJE DE SENSORES

A continuación se presenta una lista de los sensores instalados en el vehículo utilizado para las pruebas. El montaje de los sensores se ve ilustrado en la Figura 2:

1. 1 LiDAR Velodyne HDL-64E, 10 Hz, 64 haces, 0.09° de resolución angular, 2 cm de precisión en distancia, recolecta ~1.3 millones de puntos/segundo, campo de visión: 360° horizontal, 26.8° vertical, rango: 120 m
2. 4 cámaras IDS 2D uEye UI-3280CP Rev. 2, 5.04 megapíxeles, Sony IMX264 2/3" CMOS

3. 1 cámara IDS 2D uEye UI-3270CP Rev. 2, 3.17 megapíxeles, Sony IMX265 1/1.8" CMOS
4. 1 IMU xsens MTi-610, rango de medición del giróscopo de 2000°/s, rango de medición del acelerómetro de 10g
5. 2 placas GPS simpleRTK2B, módulo u-blox ZED-F9P
6. 2 antenas u-blox GNSS Multibanda ANN-MB-00 (IP67)
7. 1 micrófono Behringer ECM8000, omnidireccional con sensibilidad de 70 dB y respuesta en frecuencia de 20-20K Hz

	Laterales	Frontales	Trasera
Longitud Focal (mm)	8	5	9-90
Apertura (f stop)	1.40	2.80	1.8
Resolución H	2456	2456	2064
Resolución V	2054	2054	1544
FOV H	56°	81°	50°
FOV V	48°	71°	43°

Tabla I: Especificación de las cámaras

El LiDAR se colocó en una ubicación central elevada en el vehículo, en el techo, para maximizar su campo de visión y minimizar los puntos ciegos, para una completa percepción del entorno, facilitando la detección y el mapeo de objetos en todas las direcciones.

Las cámaras instaladas en el vehículo se dividen en tres grupos (ver Figura 3 y Tabla I), dos cámaras uEye UI-3280CP Rev. 2 cada una con un lente HR F2.8/5 mm apuntadas hacia adelante, dos cámaras uEye UI-3280CP Rev. 2 cada una con un lente HR F1.4/8 mm orientadas hacia los costados, y por último, una cámara uEye UI-3270CP Rev. 2 con un lente H990VIR 1/2" F1.8/9-90 apuntando hacia atrás. Se consideró importante que las cámaras delanteras estén sincronizadas para tener la posibilidad de tratarlas y procesarlas como una sola cámara estéreo. También es necesario que haya al menos una captura de estas cámaras por giro de LiDAR. Como el sistema en ROS no provee por cuando ocurre un giro completo de LiDAR, se construyó un sistema de gatillado con un imán montado en la parte inferior del cuerpo rotatorio del LiDAR, y un sensor de efecto Hall montado en la parte inferior del LiDAR. En régimen de funcionamiento nominal esto genera 10 cuadros por segundo de las cámaras.

La configuración de las antenas GNSS en la parte delantera y trasera del vehículo no solo permite la determinación precisa de la ubicación, sino que también facilita la estimación de la orientación del vehículo mediante el cálculo de la línea base entre las antenas. Esta información es vital para las funciones de navegación y posicionamiento del vehículo autónomo, especialmente en situaciones donde la precisión es fundamental, como en el caso de maniobras de conducción delicadas o en entornos urbanos densos.

La IMU se colocó en el centro del parabrisas trasero y provee datos de velocidad angular, orientación y fuerza específica. Se utiliza un soporte de tres puntos construido ad-hoc y montado sobre ventosas. Luego de varias pruebas, se decidió montar la IMU sobre el parabrisas trasero para minimizar las significativas distorsiones magnéticas causadas por la carrocería metálica del vehículo, lo que es crucial para mantener la integridad de los datos del magnetómetro. Este

posicionamiento centralizado también beneficia la captura de datos de aceleración y orientación, proporcionando lecturas más estables y representativas del movimiento real del vehículo.

El micrófono Behringer ECM8000 se implementó para capturar sonidos ambientales, lo que puede ser de gran utilidad para detectar la presencia de sirenas de vehículos de emergencia, bocinas, y otros sonidos relevantes que puedan influir en las decisiones de conducción. Esta inclusión de datos auditivos ofrece una capa adicional de percepción que puede mejorar la toma de decisiones del vehículo en situaciones complejas.

IV. BASE DE DATOS

Para capturar y grabar las mediciones de los sensores se implementó un sistema en ROS Noetic, el cual graba en una *rosvbag* los datos que luego se procesan para obtener la estructura de archivos presentada en la Figura 4.

Esta organización facilita la identificación y el acceso a los conjuntos de datos basados en su ubicación geográfica, lo cual es esencial para el análisis contextual y la validación de algoritmos en diversos entornos. Se tomó una estructura similar a bases de datos ya existentes en el campo para que sea sencillo reutilizar algoritmos que fueron pensados para usarse con estas otras bases de datos.

Dentro de este directorio principal, los datos se dividen en escenas. Estas escenas se refieren a segmentos cortos de la grabación (aproximadamente 10 segundos) que, desde una perspectiva semántica, representan un único desafío o situación para la conducción. Cada uno de estos segmentos se agrupa por separado dentro de un número de escena distinto. Ejemplos de escenas incluyen interacciones en semáforos, cruces peatonales, pasos a nivel ferroviarios, rotondas, entre otros. Esta clasificación por escenas es fundamental para enfocar el análisis y la evaluación en situaciones de conducción específicas y críticas. Esta segmentación de escenas se hace manualmente.

Por cada escena, los datos se organizan por tipo de sensor, lo que permite un acceso directo y estructurado a la información específica de cada dispositivo utilizado en la recopilación de datos. Los sensores incluyen:

- **Cámaras:** Proporcionan imágenes que capturan el entorno visual desde el vehículo.
- **LiDAR:** Ofrece nubes de puntos de la estructura tridimensional del entorno circundante.
- **GPS:** Registra la ubicación geográfica precisa y la trayectoria del vehículo.
- **IMU:** Proporciona datos de movimiento y orientación del vehículo, como la aceleración y la rotación.
- **Micrófono:** Permite obtener sonidos del ambiente circundante al vehículo.

Los datos de GPS e IMU se encuentran en texto plano y se provee un archivo `dataformat.txt` que detalla el formato en que se almacena la información dentro de cada archivo.

Cada sensor posee un archivo `timestamps.txt` que relaciona toda medición (*frame* del sensor) con el tiempo en que fue obtenido. Para el sensor LiDAR, al poseer

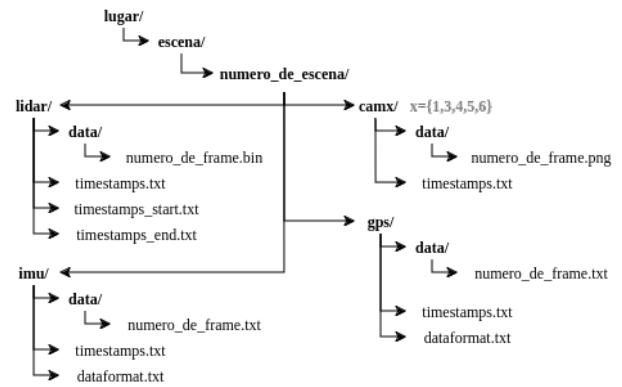


Figura 4: Estructura de la base de datos




Figura 5: Patrones de calibración visual y de relieve para LiDAR con orificios (imagen de referencia tomada de [1]).

un componente mecánico que gira, se proveen los tiempos de comienzo y finalización de cada giro, registrados en `timestamps_start.txt` y `timestamps_end.txt`. Para todos estos tiempos se usan los reportados por el reloj del sistema. Este sistema de etiquetado de mediciones es crucial para sincronizar los datos entre los distintos sensores, permitiendo un análisis integrado y coherente considerando los instantes en que la información fue recopilada. La precisión en la sincronización es esencial para el desarrollo de sistemas de conducción autónoma, ya que permite una interpretación precisa y contextual del entorno basada en la fusión de datos de múltiples sensores.

V. CALIBRACIÓN DE SENSORES

Previo a la recolección de los datos, se realizó una serie de procedimientos de calibración, de manera de garantizar la precisión y coherencia de la información recopilada por los sensores. Se proveen dos tipos de calibraciones, calibraciones intrínsecas para cada uno de los sensores y calibraciones extrínsecas entre sensores. Las calibraciones intrínsecas permiten caracterizar efectivamente cada sensor utilizando diferentes modelos matemáticos, por ejemplo, en el caso de la IMU se definen sus parámetros de ruido y sesgo (*bias*) existentes en cada uno de sus ejes. Las calibraciones extrínsecas dan cuenta de la relación espacial (traslación, rotación) que existe entre los diferentes sensores para que la información recopilada pueda ser utilizada correctamente por los diferentes métodos y algoritmos de percepción y navegación.

Procesos de calibraciones intrínsecas realizadas:

- **Magnetómetro e IMU:** Se eliminan distorsiones en las mediciones del magnetómetro realizando una calibración de hierro duro y blando (*Hard-Soft Iron*) [2], permitiendo transformar el elipsoide sesgado y distorsionado de las mediciones a una esfera centrada en el origen. Se llevó a cabo una calibración en el plano realizando giros de 360° con un desplazamiento perpendicular al vector gravedad. Se provee, además, la densidad del ruido (*noise density*) y del camino aleatorio (*random walk*) para el giroscopio y el acelerómetro. Se utilizó la medida de varianza de Allan (*Allan Variance*) [3] sobre un conjunto de muestras tomadas con el sensor en reposo durante cuatro horas.²
- **Cámaras:** Se proveen parámetros de distorsión radial (*radial distortion*) y distorsión tangencial (*tangential distortion*), así como también la distancia focal (*focal length*) y punto principal (*principal point*), para cada una de las cámaras. Para esto, se tomaron numerosas muestras de un patrón de calibración en movimiento recorriendo el perímetro completo del vehículo en movimiento, Fig. 5, utilizando el paquete de calibración multi-cámara Kalibr [4].

Procesos de calibraciones extrínseca realizadas:

- **Entre cámaras:** Se proveen las transformaciones (traslación y rotación) entre los centros ópticos de todas las cámaras, definiendo un origen de coordenadas en la cámara frontal izquierda. Esto se logró tomando muestras de un patrón de calibración en movimiento entre los campos de visión (*field of view*) de las cámaras utilizando nuevamente el paquete de calibración multi-cámara Kalibr [4].
- **Cámaras - IMU:** La transformación entre el sistema de coordenadas de las cámaras y la IMU se obtuvo tomando muestras de un patrón fijo, mientras el vehículo realizaba movimientos circulares a su alrededor, esto permite contrastar la información de movimiento percibida por la unidad inercial, con la información de movimiento relativo calculado entre las cámaras y el patrón visual. Nuevamente se utilizó el paquete de calibración Kalibr el cual es capaz de trabajar con mediciones visual-inerciales [5].
- **Cámaras - LiDAR:** La transformación entre el sistema de coordenadas de las cámaras y el sensor de rango LiDAR, se realizó tomando muestras de un patrón visual especialmente diseñado con orificios. Esto permite la detección del patrón utilizando el sensor de rango LiDAR, dado que los orificios proveen un relieve de contraste que puede ser contrastado con la detección visual (Fig. 5). Se utiliza el paquete de calibración OpenCalib [1].
- **Cámaras - GPS:** La transformación entre el sistema de coordenadas de las cámaras y el centro del receptor GPS se calculó realizando una medición manual mediante niveles láser. Se planea utilizar, en el futuro, métodos de auto-calibración integrando información inercial y visual [6].

- **Cámaras - Micrófono:** La transformación entre el sistema de coordenadas de las cámaras y el micrófono se calculó realizando mediciones manuales, pero es interesante destacar que se montó una señal sonora ubicada detrás del patrón de calibración visual. Se planea investigar métodos que permitan utilizar esta información para calibrar aspectos del modelo sonoro del micrófono.

En algunos casos, los métodos de calibración extrínseca fueron inicializados con valores calculados por medio de una calibración manual utilizando instrumentos de medición.

VI. COMPARACIÓN CON OTRAS BASES DE DATOS

Existe una variedad de bases de datos con características similares a las propuestas. Nos estaremos concentrando en las bases de datos que utilizan un automóvil como plataforma y se grabaron en áreas urbanas. La Tabla II muestra los detalles básicos de cada una de las bases de datos mencionadas a continuación.

Dataset	Lugar de grabación	Sensores				
		Cámaras	LiDAR	GPS	IMU	Micrófono
DARPA	California	✓	✓			
Ford campus	Michigan	✓	✓	✓	✓	
KITTI	Karlsruhe	✓	✓	✓	✓	
Málaga	Málaga	✓	✓	✓	✓	
MPO	Fukuoka	✓	✓	✓		
Oxford	Oxford	✓	✓	✓	✓	
ApolloScape	China	✓	✓	✓	✓	
Complex urban	Corea del sur	✓	✓	✓	✓	
Waymo	California y Arizona	✓	✓			
nuScenes	Boston y Singapur	✓	✓	✓	✓	
Nuestro dataset	Buenos Aires	✓	✓	✓	✓	✓

Tabla II: Comparación de datasets de vehículos autónomos

Una de las primeras bases de datos importantes fue *DARPA* [7] grabada por el *MIT* justamente durante el desafío DARPA del 2007. La grabación tiene datos de un recorrido de 90 km en lo que en su momento fue una base de la fuerza aérea estadounidense en California. El vehículo utilizado para grabar la base de datos *Ford Campus* [8], también compitió en el desafío DARPA del 2007. Esta base de datos graba 6 km de recorridos entre el campus de investigación de Ford y el centro de Dearborn en Michigan. Sin dudas una de la base de datos más utilizada hasta el momento es *KITTI* [9]. Esta base de datos es usada para probar el desempeño de distintos algoritmos de SLAM y segmentación semántica. Presenta grabaciones de 39,2 km en las calles de Karlsruhe en Alemania. La base de datos *Málaga* [10] presenta diversidad en ambientes urbanos de alta concurrencia, los datos se grabaron en un recorrido de 36.8 km por las calles de Málaga, España. *Multi-modal Panoramic 3D Outdoor (MPO)* [11] es una base de datos que fue hecha con la intención de poder hacer clasificación semántica de ambientes. Por lo que tiene datos en bosques, costas, estacionamientos, áreas residenciales y urbanas en Fukuoka, Japón. Otro ejemplo es la base de datos *Oxford* [12] que

²software utilizado: https://github.com/ori-drs/allan_variance_ros

se destaca por tener más de 1000 km de datos a lo largo de año y medio en ambientes diversos de Oxford. Su ruta principal fue recorrida más de 100 veces en distintos momentos del día y diversas condiciones climáticas. La base de datos *ApolloScape* [13] fue grabada a lo largo de cuatro regiones de China en diversas condiciones, pero se focaliza principalmente a la segmentación semántica de los datos capturados. La base de datos armada por KAIST, *Complex urban* [14] contiene datos de alrededor de 190 km en distintas ciudades de Corea del sur. Contiene escenas de áreas metropolitanas, áreas residenciales, complejos departamentales, autopistas, túneles y puentes. En el caso de la base de datos *Waymo* [15], ésta graba solamente datos de cámaras y LiDAR en San Francisco, Mountain View y Phoenix, cubriendo un área de 76 km² entre las tres ciudades. Por su parte, *nuScenes* [16] declara ser la primera base de datos usando un vehículo autónomo aprobado para calles públicas. Presenta una colección completa de anotaciones semánticas con cajas volumétricas 3D.

VI-A. Valor agregado de la base de datos propuesta

La base de datos propuesta presenta un valor agregado significativo al ofrecer un conjunto diversificado de escenas de calles del AMBA, lo que representa un avance crucial para la investigación en conducción autónoma en América Latina. Esta diversidad geográfica y cultural permite la identificación de fenómenos específicos relevantes para la navegación en la región. Como se puede observar en la Figura 6, estos fenómenos pueden incluir calles no bien señalizadas, ciclistas, autos mal estacionados, lomas de burro y cartoneros. Estas características distintivas ofrecen una valiosa oportunidad para entrenar y evaluar algoritmos de conducción autónoma en escenarios realistas y variados, mejorando así su capacidad para adaptarse a las condiciones de conducción únicas de los países latinoamericanos.

VII. RESULTADOS EXPERIMENTALES

Si bien el dataset se grabó en su integridad conduciendo manualmente siguiendo la reglamentación local; también se realizaron ensayos de conducción autónoma con el propósito de mostrar la utilidad de la información provista por los sensores para realizar el control del vehículo. En el ensayo que se presenta en este trabajo, se programó el vehículo para que siguiera un camino predefinido, para lo cual se utilizó una adaptación del algoritmo de persecución plena de [17], combinado con un módulo que controla la caja de cambios y presiona gradualmente el freno cuando se llega a destino. En las Figuras 7 y 8 se observa el auto conduciéndose autónomamente de esta manera.

El algoritmo implementado fusiona en tiempo real información de la IMU y del GPS-RTK para calcular la posición y orientación del vehículo. Si bien el sistema adquiere información de las cámaras y del LiDAR, esta información fue utilizada solamente para demostrar que el vehículo tiene la capacidad de percibir su entorno. El algoritmo de control implementado no es reactivo a este cambio en el entorno. En

todos los experimentos realizados, el vehículo logró mantener un error de seguimiento inferior al metro.

VIII. CONCLUSIONES

En este trabajo presentamos una nueva base de datos diseñada específicamente para la investigación y el desarrollo en el campo de la conducción autónoma, con un enfoque particular en las características y desafíos únicos del entorno urbano argentino. Nuestra base de datos recopila información integral de múltiples fuentes sensoriales, incluyendo cámaras, LiDAR, GPS, IMU y micrófono, proporcionando una representación rica y multifacética del entorno circundante.

En el futuro se planea extender la base de datos capturando información de diversas áreas urbanas de la República Argentina. También sería posible analizar y evaluar los algoritmos de conducción autónoma ya existentes con los datos registrados en esta base de datos.

AGRADECIMIENTOS

Agradecemos a las instituciones que nos ayudaron económicamente a desarrollar el proyecto: 123Seguro, SANCOR Seguros, Etermax, MercadoLibre y Globant. Queremos también agradecer a Voyage por la donación del vehículo utilizado y los servicios otorgados por Juan Bartolomé. Finalmente, nada de esto sería posible sin el trabajo de William Boyd.

REFERENCIAS

- [1] G. Yan, Z. Liu, C. Wang, C. Shi, P. Wei, X. Cai, T. Ma, Z. Liu, Z. Zhong, Y. Liu, M. Zhao, Z. Ma, and Y. Li, "Opencalib: A multi-sensor calibration toolbox for autonomous driving," *arXiv preprint arXiv:2205.14087*, 2022.
- [2] T. Ozyagcilar, "Calibrating an ecompass in the presence of hard and soft-iron interference," *Freescale Semiconductor Ltd*, pp. 1–17, 2012.
- [3] O. J. Woodman, "An introduction to inertial navigation," University of Cambridge, Computer Laboratory, Tech. Rep., 2007.
- [4] P. Furgale, J. Rehder, and R. Siegwart, "Unified temporal and spatial calibration for multi-sensor systems," in *2013 IEEE/RSJ International Conference on Intelligent Robots and Systems*. IEEE, 2013, pp. 1280–1286.
- [5] J. Rehder, J. Nikolic, T. Schneider, T. Hinzmänn, and R. Siegwart, "Extending kalibr: Calibrating the extrinsics of multiple imus and of individual axes," in *2016 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2016, pp. 4304–4311.
- [6] R. Gonzalez, J. I. Giribet, and H. D. Patino, "Navego: A simulation framework for low-cost integrated navigation systems," *Journal of Control Engineering and Applied Informatics*, vol. 17, no. 2, pp. 110–120, 2015.
- [7] A. S. Huang, M. Antone, E. Olson, L. Fletcher, D. Moore, S. Teller, and J. Leonard, "A high-rate, heterogeneous data set from the darpa urban challenge," *The International Journal of Robotics Research*, vol. 29, no. 13, pp. 1595–1601, 2010.
- [8] G. Pandey, J. R. McBride, and R. M. Eustice, "Ford campus vision and lidar data set," *The International Journal of Robotics Research*, vol. 30, no. 13, pp. 1543–1552, 2011.
- [9] A. Geiger, P. Lenz, C. Stiller, and R. Urtasun, "Vision meets robotics: The KITTI dataset," *The International Journal of Robotics Research*, vol. 32, no. 11, p. 1231, 2013, originally published online on 23 August 2013.
- [10] J.-L. Blanco-Claraco, F.-A. Moreno-Duenas, and J. González-Jiménez, "The Málaga urban dataset: High-rate stereo and lidar in a realistic urban scenario," *The International Journal of Robotics Research*, vol. 33, no. 2, pp. 207–214, 2014.
- [11] H. Jung, Y. Oto, O. M. Mozos, Y. Iwashita, and R. Kurazume, "Multi-modal panoramic 3d outdoor datasets for place categorization," in *2016 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. IEEE, 2016, pp. 4545–4550.



Figura 6: Algunos ejemplos de fenómenos que se pueden encontrar en la base de datos.



Figura 7: (a) Vehículo siguiendo de manera autónoma un camino programado. (b) Esquema de percepción del vehículo utilizando información del LIDAR.

- [12] W. Maddern, G. Pascoe, C. Linegar, and P. Newman, "1 year, 1000 km: The oxford robotcar dataset," *The International Journal of Robotics Research*, vol. 36, no. 1, pp. 3–15, 2017.
- [13] P. Wang, X. Huang, X. Cheng, D. Zhou, Q. Geng, and R. Yang, "The Apolloscape open dataset for autonomous driving and its application," *IEEE transactions on pattern analysis and machine intelligence*, 2019.
- [14] J. Jeong, Y. Cho, Y.-S. Shin, H. Roh, and A. Kim, "Complex urban dataset with multi-level sensors from highly diverse urban environments," *International Journal of Robotics Research*, vol. 38, no. 6, pp. 642–657, 2019.
- [15] P. Sun, H. Kretzschmar, X. Dotiwalla, A. Chouard, V. Patnaik, P. Tsui, J. Guo, Y. Zhou, Y. Chai, B. Caine *et al.*, "Scalability in perception for autonomous driving: Waymo open dataset," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2020, pp. 2446–2454.
- [16] H. Caesar, V. Bankiti, A. H. Lang, S. Vora, V. E. Liong, Q. Xu, A. Krishnan, Y. Pan, G. Baldan, and O. Beijbom, "nusenes: A multimodal dataset for autonomous driving," in *CVPR*, 2020.
- [17] R. C. Coulter *et al.*, *Implementation of the pure pursuit path tracking algorithm*. Carnegie Mellon University, The Robotics Institute, 1992.



Figura 8: Vehículo siguiendo un camino programado en un terreno irregular.